

As Gêmeas e o Número

Resumo executivo — compressão por inteligência compartilhada

Antônio Alberto Lopes Elias · ORCID [0000-0002-5602-9916](#)
Sounavy — GaIA / Opera Vox · trabalho independente, sem afiliação institucional · setembro de 2026

Versão condensada de As Gêmeas e o Número: Compressão por Inteligência Compartilhada (paper completo, 37 asserções testadas, código e hashes no repositório). Este documento existe para leitura em cinco minutos, não para substituir o original.

Uma frase

Duas partes que compartilham um modelo probabilístico só precisam trocar $H(X|M)$ bits, não $H(X)$. O restante é engenharia: fazer duas instâncias de modelo concordarem, bit a bit, apesar de rodar em hardware, versões e — no caso de LLMs — inferências não-idênticas.

Este trabalho (a) reproduz esse resultado com um codificador aritmético inteiro, sem LLM, para isolar o mecanismo; (b) mede empiricamente a fragilidade de sincronização entre "gêmeas" e confirma, por caminho independente, o achado central de Adler & Tang (ICLR 2026); (c) registra três extensões pequenas e verificáveis — não uma arquitetura nova, três peças de engenharia com número ao lado.

Resultados que sustentam o resto

#	ACHADO	MEDIDA
1	Dicionário prévio compartilhado reduz o canal	20,07% menos bits, mesmo codec, mesmo texto
2	O fluxo comprimido é, literalmente, um único inteiro	576 bits → 166 bits (frase de 72 caracteres)
3	Camada de contexto opcional, portão sem custo de sinalização	prejuízo de -2,81% → 0% (decisão deduzida do bloco anterior)
4	Redundância proporcional à importância (RRNS aplicado ao stream)	0 → 31 bits compram detecção → correção de até 2 erros
5	Tolerância numérica entre gêmeas: nenhuma	erro de $\pm 1/4096$ em toda decisão → 100% de falha no primeiro byte
6	Falha pontual (1 contador, 1 bit) é majoritariamente silenciosa	sobrevive em 93% dos casos, destrói em 7% — sem aviso

Cada linha corresponde a uma função Python que roda sozinha, sem dependência, em ~40s no total (`paper/prova/roda_tudo.py`). O cabeçalho do relatório gerado traz o SHA-256 de cada arquivo de código e de corpus usado — qualquer divergência entre o que está aqui e o que roda localmente é erro do documento, não de quem reproduziu.

O achado 5 e sua relação com trabalho publicado

O item 5 é o resultado que temos mais confiança em recomendar a esta leitora especificamente. Ele foi obtido de forma independente — implementação própria, sem LLM, modelo de mistura de contexto em aritmética inteira — e converge com o resultado central de:

Adler, A.; Tang, J. *Synchronizing Probabilities in Model-Driven Lossless Compression*. ICLR 2026. arXiv:2601.10678.

que demonstra, com LLaMA 3.1 em hardware real (M2 Pro → M4 Max), que codificação aritmética padrão falha *totalmente* sob divergência de hardware, e que PMATIC (tolerância explícita a mismatch, custando $\sim 3\times$ em bits) resolve o problema.

Também citamos, por estar em diálogo técnico direto com o mesmo espaço de problema:

Rinberg, R.; Carrell, A. M.; Henniger, S.; Carlini, N.; Warr, K. *Haiku to Opus in Just 10 bits: LLMs Unlock Large Compression Gains*. arXiv:2604.02343, 2026. (Harvard, Cambridge, Anthropic.)

Este último demonstra ganhos de $2\times$ via adaptação de domínio (LoRA) sobre codificação aritmética com LLM, e um protocolo interativo de perguntas binárias que recupera 7–72% da diferença de capacidade entre modelos com apenas 10 bits transmitidos. Não reproduzimos esses números — citamos porque situam este trabalho dentro de uma linha de pesquisa ativa, não fora dela.

O que é rigor aqui, e o que é conjectura

Onze das 37 asserções do paper completo foram refutadas pela própria medição e permanecem publicadas como tal — vetor de primos como compressão (expande $79,4\times$), busca de semente curta (custo 2^k para <1 bit de ganho), paridade de posição como sinal (0,000 bit líquido sob controle de embaralhamento), entre outras. Nenhuma foi removida após cair; cada uma tem a medição e a data que a derrubou.

Isto não é uma pretensão de completude acadêmica. É a razão prática pela qual os seis resultados acima merecem cinco minutos: o mesmo processo que os produziu já demonstrou, dentro do próprio corpo de trabalho, que sabe reconhecer e publicar o que não funciona.

Reproduzir

```
git clone https://github.com/dralbertoeliasBr/BOLINHA-.git
cd BOLINHA- && git checkout claude/llm-gemeas-compressao-lwnpwn
python3 paper/prova/roda_tudo.py
```

Python 3.8+, zero dependências externas. Roda em desktop ou, deliberadamente, em Pythonista/a-Shell num iPhone — a restrição de ambiente é parte do projeto, não uma limitação a esconder.

O que este documento não é

Não é proposta de investimento. Não há modelo de negócio anexo, nem pretensão de startup. É a solicitação mais simples possível: que os seis resultados acima, e em particular o item 5, sejam avaliados por quem já trabalha na fronteira exata deste problema — porque uma confirmação independente, mesmo pequena, tem valor para quem projeta sistemas que dependem de duas inferências concordarem.

Contato e citação completa: paper integral, código, e os demais documentos desta linha de trabalho (método, prova de colaboração, origem) em `github.com/dralbertoeliasBr/BOLINHA-`, branch `claude/llm-gemeas-compressao-lwnpwn`, pasta `obra/`.

Elias, A. A. L. (2026). *As Gêmeas e o Número: Compressão por Inteligência Compartilhada*. Sounavy — GaIA / Opera Vox. ORCID 0000-0002-5602-9916.